Semillero de Investigación

David Steven Ospina Morales

Fundación Universitaria Área Andina

Facultad De Ingeniería

Docente, Raul Bareño Gutiérrez

Bogotá D.C

Marzo 2026

1. Diseño del Esquema de Tablas (Modelo Entidad-Relación)

Para soportar proyectos, versiones y usuarios, se propone un esquema relacional que garantiza la trazabilidad de los datos:

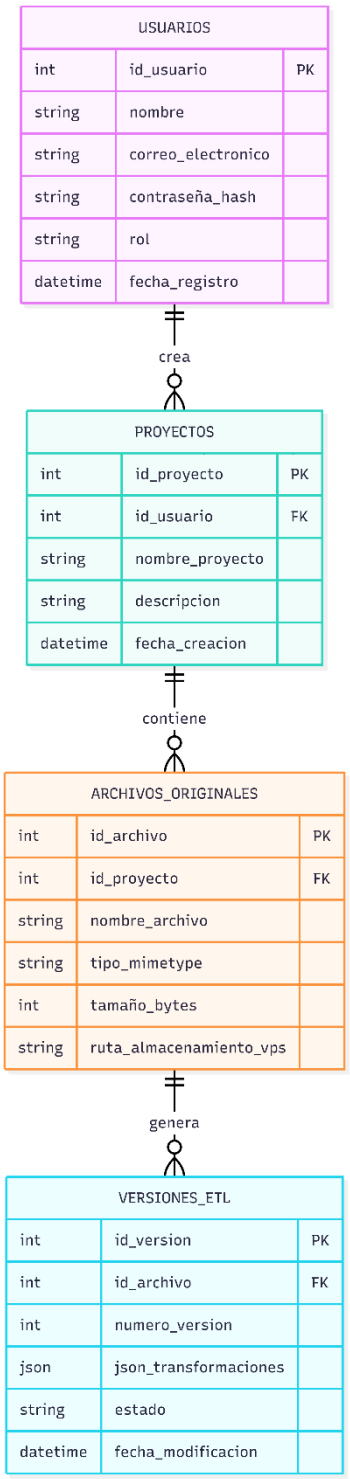

2. Metadatos Mínimos para la IA

Para que el modelo pueda realizar una limpieza efectiva sin procesar gigabytes innecesarios de texto, la aplicación debe extraer y enviarle estos metadatos:

- **Estructura**: Lista de nombres de columnas y tipos de datos detectados (int, float, object).
- **Calidad**: Conteo de valores nulos por columna y porcentaje de duplicados totales.
- **Muestra**: Primeras 5 filas y últimas 5 filas (para contexto semántico).
- **Estadísticas**: Media, mediana y desviación estándar para columnas numéricas.
- **Cardinalidad**: Número de valores únicos en columnas categóricas (ayuda a identificar IDs o etiquetas).

3. Reglas de Negocio (Extraídas del Documento Técnico)

Basado en el análisis del documento estas son las reglas que la arquitectura debe respetar:

- **Validación de Carga (RF02):** No permitir archivos que superen los 200MB (CSV) o 50MB (Excel).
- **Tiempo de Respuesta Conversacional (RNF01):** El flujo de comunicación con la IA no debe exceder los 3 segundos para mensajes de texto.
- **Eficiencia de Reportes (RF04):** La generación del tablero tras la limpieza debe ocurrir en menos de 30 segundos.
- **Intercambiabilidad de IA (RNF07):** La arquitectura debe ser de N-Capas con una "Capa de Servicio de IA" desacoplada, permitiendo cambiar de Moonshot AI a Gemini o GPT-4o sin afectar el núcleo del negocio.

4. Flujo de Secuencia: Limpieza de Datos
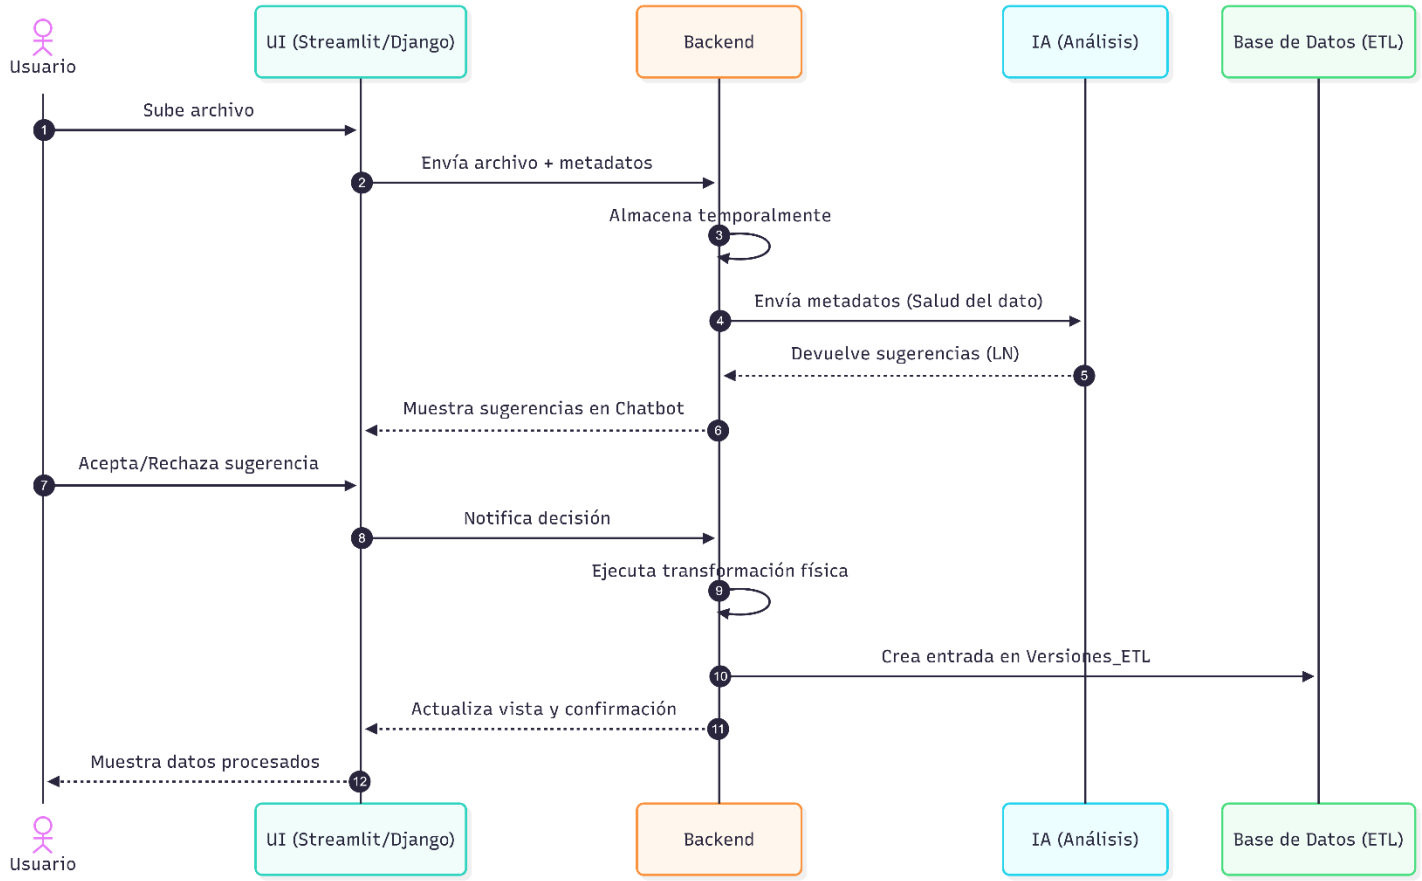
Este es el flujo lógico que debe seguir el sistema para la tarea de ETL asistida: