Google Colab y TOON en la automatización de procesos ETL con IA

Nestor Johao Zuleta Montealegre

Corporación Unificada Nacional de Educación Superior CUN

Programa de Ingeniería de Sistemas

Prácticas 1 Código 56651

2026

Contenido

Resumen....5
Abstract....5
Introducción....6
1. Planteamiento del problema....7
1.1. Descripción del problema....7
1.2. Pregunta de investigación....7
1.3. Justificación....8
1.4. Objetivos de la investigación....8
1.4.1. Objetivo general....8
1.4.2. Objetivos específicos....8
2. Marco teórico....10
2.1. Fundamentos de ETL (Extracción, Transformación, Carga)....10
2.1.1. Concepto y evolución....10
2.1.2. Fases del proceso ETL....10
2.1.3. ETL tradicional vs. ETL moderno....11
2.2. Inteligencia Artificial en procesos de datos....11
2.2.1. Transformación del Paradigma ETL....11
2.2.2. Aplicaciones de IA en ETL....11
2.3. Google Colaboratory: Plataforma Cloud para Ciencia de Datos....12
2.3.1. Definición y características fundamentales....12
2.3.2. Arquitectura y capacidades computaciones....13
2.3.3. Integración de Inteligencia Artificial en Colab....13
2.3.4. Ventajas principales....14
2.3.5. Limitaciones....15
2.4. Token-Oriented Object Notation (TOON)....15
2.4.1. Contexto y motivación....15
2.4.2. Arquitectura y especificación técnica....16
2.4.3. Benchmarks y rendimiento....18
2.4.4. Escenarios ideales para TOON....19
2.4.5. Limitaciones documentadas....19
2.4.6. Implementaciones y ecosistemas....20
2.5. Automatización de Procesos ETL con Inteligencia Artificial....20
2.5.1. Contexto de ETL Tradicional vs. ETL impulsado por IA....20

2.5.2. Capacidades de IA en cada fase ETL 21
2.5.3. Herramientas ETL con IA del mercado 22
2.5.4. Aplicaciones empresariales reales 23
2.5.5. Tendencias emergentes 24
3. Metodología 25
3.1. Tipo de investigación 25
3.2. Enfoque metodológico 25
3.3. Diseño de investigación 26
3.4. Nivel de investigación 26
3.5. Métodos y técnicas de recolección 26
3.6. Fuentes de Información 27
3.7. Procedimiento de Análisis 27
3.8. Limitaciones metodológicas 28
4. Resultados 29
4.1. Integración de Google Colab y TOON en Automatización ETL con IA 29
4.1.1. Sinergia Arquitectónica 29
4.1.2. Arquitectura de referencia propuesta 30
4.1.3. Beneficios Cuantificables de la Integración 33
4.1.4. Consideraciones y limitaciones 33
4.2. Oportunidades de Desarrollo e Integración 34
4.2.1. Áreas de Investigación y Desarrollo 34
4.3. Integración con ecosistema de herramientas 35
4.3.1. Integración con Airflow 36
4.3.2. Integración con dbt (data build tool) 36
4.3.3. Integración con Great Expectations 36
4.4. Aplicaciones Avanzadas de IA 36
4.4.1. Transfer Learning para Mapeo de Schemas 37
4.4.2. Reglas de Calidad Automáticas 37
4.4.3. Optimización con Refuerzo 37
4.4.4. Documentación por NLP 37
5. Discusión 38
5.1. Interpretación de hallazgos 38
5.2. Contraste con literatura existente 38
5.3. Implicaciones prácticas 38
5.3.1. Para organizaciones pequeñas y medianas 38

5.3.2. Para instituciones educativas 39
5.3.3. Para científicos de datos e investigadores 39
5.3.4. Para empresas con datos sensibles 39
5.4. Limitaciones del Estudio 39
5.5. Contribuciones al Conocimiento 40
5.6. Direcciones futuras de investigación 40
6. Conclusión y recomendaciones 42
6.1. Síntesis y hallazgos principales 42
6.2. Recomendaciones para Implementación 42
6.2.1. Al empezar automatización ETL con IA 42
6.2.2. Si ya se tiene procesos ETL automatizados en marcha 42
6.2.3. Para desarrolladores de herramientas ETL 42
6.3. Reflexión Final 43
Referencias 44
Glosario de términos 49

Resumen

Esta investigación explora cómo Google Colab y TOON ayudan a automatizar procesos ETL con el uso de inteligencia artificial (IA). Con un enfoque documental cualitativo descriptivo-exploratorio, analiza qué ofrecen estas herramientas, sus límites y cómo se complementan para hacer más eficientes los flujos de datos. Entre los resultados destaca que Colab facilita el acceso a recursos potentes de cómputo, mientras TOON reduce entre un 30 y un 60% los costos de tokens en Modelos de Lenguaje Grande (LLMs). Su combinación trae mejoras concretas en eficiencia, costos y estabilidad, pero hay que considerar temas de seguridad, escalabilidad y usos adecuados.

Palabras clave: Google Colab, TOON, ETL, Inteligencia Artificial, Automatización de Datos, Machine Learning.

Abstract

This research explores how Google Colab and TOON facilitate the automation of ETL processes using Artificial Intelligence (AI). Employing a qualitative, descriptive-exploratory documentary approach, the study analyzes the capabilities and limitations of these tools, as well as how they complement each other to optimize data workflows.

Key findings highlight that Colab grants access to high-performance computing resources, while TOON reduces token costs for Large Language Models (LLMs) by 30% to 60%. Their integration yields tangible improvements in efficiency, cost-effectiveness, and stability; however, considerations regarding security, scalability, and appropriate implementation must be addressed.

Keywords: Google Colab, TOON, ETL, Artificial Intelligence, Data Automation, Machine Learning.

Introducción

Esta investigación revisa dos herramientas tecnológicas geniales en la escena de ciencia de datos y procesamiento de información: Google Colaboratory (Colab) y Token-Oriented Object Notation (TOON), analizando cómo podrían automatizar las tareas ETL (Extraer, Transformar, Cargar) mediante el uso de IA. El desglose muestra que ambas herramientas aportan fortalezas únicas a la mesa que, cuando se usan juntas de manera inteligente, pueden cambiar totalmente el juego en cuanto a cómo manejamos la eficiencia de los datos, los costos y el escalado.

En la actualidad, el mundo del procesamiento de datos confronta problemas considerables: Las compañías están saturadas de información, los costos de infraestructura son exorbitantes y los flujos de trabajo tradicionales demandan atención permanente. Ahí es donde Colab y TOON entran en juego con algunas soluciones prácticas y, lo que es más importante, fáciles de usar.

1. Planteamiento del problema

1.1. Descripción del problema

Los procesos ETL son el corazón de la integración de datos en las empresas actuales. Como señala IBM (s.f.), forman la base para análisis y machine learning al juntar, limpiar y ordenar información de fuentes diversas. Pero los métodos tradicionales tropiezan con problemas serios que frenan su eficiencia y capacidad de crecer.

Estos pipelines exigen codificación manual a fondo para cada fuente, transformación y mapeo, lo que lleva tiempo y abre la puerta a errores. Si cambian las estructuras de los datos originales, todo se cae y toca ajustar reglas manualmente (Tecnología BI, 2025). Por otro lado, la inteligencia artificial y los Modelos de Lenguaje Grande (LLMs) prometen automatizar partes clave del ETL. El inconveniente es que se cobra por token procesado, y formatos como JSON gastan tokens de más por ser tan redundantes (InfoQ, 2025).

Aquí entran herramientas como Google Colab, que pone recursos potentes al alcance de todos, y TOON, creado para ahorrar tokens en chats con LLMs. Queda por ver cómo integrarlas bien para automatizar ETL, qué beneficios reales traen y dónde están sus límites.

1.2. Pregunta de investigación

¿Cómo pueden Google Colab y TOON contribuir a la automatización de procesos ETL mediante la integración de inteligencia artificial, y cuáles son los beneficios y limitaciones de su implementación?

1.3. Justificación

Automatizar procesos ETL con IA no es solo una simple optimización, sino un cambio profundo que transforma cómo se maneja la información. Este estudio tiene sentido por varias razones esenciales.

Relevancia académica: Cubre un vacío en la literatura al detallar tecnologías nuevas como Colab y TOON, cuya combinación ha recibido poca atención en estudios académicos. Esto enriquece el conocimiento sobre ingeniería de datos e IA.

Pertinencia práctica: Las empresas buscan guías claras para elegir herramientas ETL actuales. Aquí hay comparaciones, ejemplos reales y balances de costos versus ganancias.

Oportunidad tecnológica: Actualmente Colab ha evolucionado hacia un enfoque centrado en la IA al incorporar funciones agénticas (Google for Developers, 2025), TOON por su parte resuelve aquello de los tokens costosos, y la IA está redefiniendo la eficiencia en los procesos de ingeniería de datos.

1.4. Objetivos de la investigación

1.4.1. Objetivo general

Analizar el potencial de Google Colaboratory y TOON como herramientas facilitadoras para la automatización de procesos ETL mediante inteligencia artificial, evaluando sus características, capacidades, sinergia y aplicabilidad práctica.

1.4.2. Objetivos específicos

1. Caracterizar Google Colaboratory en términos de arquitectura, funcionalidades, analizando su evolución hacia un entorno Nativo de IA (AI-first), identificando las ventajas y limitaciones para desarrollo ETL.

2. Analizar TOON como formato de serialización optimizado para LLMs, considerando su especificación técnica, benchmarks de rendimiento y casos de uso apropiados.

3. Identificar cómo la inteligencia artificial transforma las fases de extracción, transformación y carga en procesos ETL modernos.

4. Proponer una arquitectura de referencia que integre Colab, TOON e IA para automatización ETL, especificando componentes y flujos de trabajo.

5. Evaluar beneficios cuantificables, limitaciones y consideraciones prácticas de la integración propuesta.

2. Marco teórico

2.1. Fundamentos de ETL (Extracción, Transformación, Carga)

2.1.1. Concepto y evolución

ETL es un proceso de integración de datos que combina, limpia y organiza información de varias fuentes en un conjunto de datos único y coherente para almacenarlo en un data warehouse, data lake u otro sistema de destino (IBM, s.f.). Este proceso se originó en la década de 1970 con el cambio hacia bases de datos centralizadas más grandes, convirtiéndose eventualmente en el método principal para procesar datos en proyectos de almacenamiento de datos.

Según Google Cloud (s.f.), ETL puede utilizarse para diversas finalidades: mover datos a almacenes para análisis colectivo, preparar información para aprendizaje automático, integrar datos de marketing desde múltiples fuentes, y procesar flujos de IoT (Internet de las Cosas).

2.1.2. Fases del proceso ETL

Extracción: Implica recopilar datos de diferentes fuentes que pueden incluir bases de datos, archivos, APIs externas y más, con diversos formatos y estructuras (Alice Biometrics, 2024).

Transformación: Fase donde se limpia, reformatea y estandariza la información aplicando reglas empresariales para abordar necesidades específicas de inteligencia de negocios (IBM, s.f.).

Carga: Movimiento de datos preparados hacia el sistema de destino, ya sea mediante procesamiento por lotes a intervalos programados o en tiempo real de forma continua (Alice Biometrics, 2024).

2.1.3. ETL tradicional vs. ETL moderno

La ETL tradicional se creó para cargas de trabajo predecibles y estructuradas en instalaciones locales, basándose en procesamiento por lotes, actualizaciones manuales y pipelines rígidos (IBM, s.f.). En contraste, la ETL moderna está diseñada para la nube, admite flujos de trabajo por lotes y de transmisión, y permite actuar sobre los datos en el momento en que se generan.

Como señala Tecnología BI (2025), la automatización de procesos ETL no solo minimiza el error humano, sino que también acelera la disponibilidad del dato para análisis, logrando decisiones más rápidas y acertadas en el negocio.

2.2. Inteligencia Artificial en procesos de datos

2.2.1. Transformación del Paradigma ETL

La inteligencia artificial altera por completo el enfoque tradicional de los procesos ETL, que pasaban de ser reactivos y dependientes de mano de obra intensiva a convertirse en sistemas proactivos e inteligentes con capacidad de autoajuste (Skyone Solutions, 2025). En lugar de mover datos de forma mecánica, la IA los entiende, responde a cambios y evoluciona con el tiempo, lo que eleva la infraestructura a un nivel activo y con criterio propio.

2.2.2. Aplicaciones de IA en ETL

Skyone Solutions (2025) explica que, gracias al Procesamiento del Lenguaje Natural (PLN) y los Modelos de Lenguaje Grande (LLM), la IA interpreta datos desordenados como textos o emails, saca lo esencial y lo prepara para análisis sin complicaciones. IBM (s.f.), a su vez, pone énfasis en cómo la IA automatiza el manejo de documentos estructurados, semi o totalmente no estructurados, eliminando la necesidad de intervenciones manuales en la captura de datos.

2.3. Google Colaboratory: Plataforma Cloud para Ciencia de Datos

Figura 1.

Logo Colab

Fuente: Google Colab

2.3.1. Definición y características fundamentales

Google Colaboratory, también conocido como Colab, es un entorno tipo Jupyter Notebook que funciona en la nube y no requiere configuración para empezar a usarse (Google Colab, s.f.). Su mayor ventaja es que permite acceso gratuito a recursos computacionales de alto rendimiento, como GPUs y TPUs, algo que normalmente requeriría una inversión considerable en equipo físico.

En su núcleo, Colab permite desarrollar y ejecutar código Python directamente desde el navegador web. La documentación oficial destaca su orientación principal hacia el machine learning, el análisis de datos y fines educativos (Google Cloud, s.f.). De esta forma, la plataforma sortea las limitaciones técnicas que históricamente han restringido el empleo de capacidades computacionales avanzadas.

Según Analytics Vidhya (2024), una de las grandes ventajas de Colab es que resuelve ese típico "Memory Error" que tanto complica a los científicos de datos cuando manejan volúmenes enormes de datos en sus computadoras locales. La plataforma trae funciones clave como la conexión directa con Google Drive, trabajo colaborativo en tiempo real (parecido a

Google Docs) y un montón de librerías ya listas para machine learning, entre ellas TensorFlow, PyTorch, Keras, Pandas, NumPy, Matplotlib y Seaborn (Geekflare, 2025).

Esto hace que todo sea más fácil, sin tener que instalar nada manualmente ni preocuparse por las limitaciones de memoria del equipo de cómputo.

2.3.2. Arquitectura y capacidades computaciones

La arquitectura de Colab se apoya en un sistema de computación en la nube que asigna recursos de forma dinámica, justo según lo que necesite cada usuario (Google Cloud, s.f.). Para los planes gratuitos, esto incluye tiempo en GPUs con procesadores Intel, aunque a nivel empresarial las exigencias de protección de datos suben varios niveles. Por eso Google lanzó Colab Enterprise, una versión más robusta de su herramienta original, pensada para ajustarse a los estándares de seguridad y cumplimiento que manejan las empresas hoy en día.

A diferencia de la opción gratis, esta edición ofrece un control total sobre la privacidad y la colaboración mediante políticas precisas de acceso vía Identity and Access Management (IAM). Como explica Google Cloud (s.f.), esa integración no solo simplifica el trabajo en equipo, sino que asegura que los datos queden bien resguardados bajo los protocolos empresariales de Google. Además, trae extras como la gestión automática de ejecuciones, plantillas personalizables, conexión con BigQuery para manejar datos masivos y opciones para programar notebooks que arranquen solos (Google Cloud, s.f.).

2.3.3. Integración de Inteligencia Artificial en Colab

En mayo de 2025, Google presentó una renovación total de Colab, convirtiéndola en una plataforma centrada en la IA, con asistencia agéntica basada en Gemini 2.5 Flash (Google Developers Blog, 2025). Esta versión actúa como un compañero real de programación, que entiende el código en curso, las acciones, intenciones y metas del usuario.

Entre sus funciones de IA destacan:

- **Generación y edición de código:** Crea funciones rápidas, plantillas básicas o reescribe notebooks enteros usando lenguaje natural (Google Developers Blog, 2025).
- **Charla sobre librerías de Python:** Ayuda a encontrar nuevas herramientas con ejemplos adaptados a lo que estás haciendo (Google Research, 2025).
- **Arreglo automático de errores:** Ante un fallo, propone soluciones paso a paso en el notebook, mostrando los cambios en una vista comparativa para que los revises (Google Developers Blog, 2025).
- **Agente de Data Science:** Estrenado en marzo de 2025 y mejorado en mayo, explora datos, hace análisis profundos y saca conclusiones por su cuenta (Google Developers Blog, 2025).

Las integraciones anteriores con Gemini han duplicado la productividad en Colab, según datos internos de Google (Google Developers Blog, 2025). Esto cambia cómo fluye el desarrollo diario.

2.3.4. Ventajas principales

Accesibilidad total: No hace falta instalar nada ni configurar hardware; solo abre tu navegador y listo para trabajar desde cualquier lado (Analytics Vidhya, 2024).

Rentabilidad pura: Te da gratis potencia de alto nivel que de otra forma saldría cara en equipo propio (Geekflare, 2025).

Colaboración sin fricciones: Comparte el notebook por un enlace y varios pueden editarlo o ejecutarlo al mismo tiempo, como en un documento compartido (Geekflare, 2025).

Conexión con Google: Se enlaza directo con Drive, BigQuery y otros servicios de la nube para manejar datos pesados sin salir de la plataforma (Google Cloud, s.f.).

Seguimiento de cambios: Puedes atarlo a repositorios de GitHub para llevar el control de versiones sin complicaciones (Google Cloud, s.f.).

2.3.5. Limitaciones

- Las sesiones gratis en Colab se cortan después de 12 horas máximo, o si las dejas paradas un buen rato (Google Cloud, s.f.).
- Depende totalmente de una conexión a internet sólida; sin ella, no hay forma de sacarle provecho completo (Analytics Vidhya, 2024).
- Los recursos que dan sin costo se comparten con todo el mundo, así que en momentos de mucha gente conectada, te puedes quedar corto (Geekflare, 2025).
- Se debe estar atento con el almacenamiento: todo lo temporal se pierde cuando cierra la sesión, por eso mejor vincúlalo a algo externo desde el principio (Google Cloud, s.f.).

2.4. Token-Oriented Object Notation (TOON)

2.4.1. Contexto y motivación

Token-Oriented Object Notation (TOON) es un formato para serializar datos, compacto y fácil de leer para cualquier persona, creado justo para sacarle el máximo provecho a los tokens cuando chateas con Modelos de Lenguaje Grande (LLMs) (GitHub toon-format, 2025). Todo viene de un problema básico con el formato JSON tradicional: resulta redundante cuando lo usas como entrada para estos modelos. Ver Figura 2.

Figura 2

Arreglo simple de usuarios en JSON

```
{
"Users": [
{"id": 1, "nombre": "María Rodríguez", "rol": "Administrador"},
{"id": 2, "nombre": "Pedro Sánchez", "rol": "Usuario"},
{"id": 3, "nombre": "Carlos Pérez", "rol": "Desarrollador"}
]
}
```

Nota. Cada objeto repite las claves "id", "nombre" y "rol". En un dataset con cientos o miles de registros, esta repetición se traduce en costos significativos. Fuente: Elaboración propia (2025).

En el análisis descrito en Apidog (2025), se explica que JSON fue creado para mover datos entre máquinas de forma que cualquier humano lo entendiera fácil y fuera universal. El lío es que, en los LLMs, cada carácter de más, claves repetidas, comas extras, se traduce en tokens consumidos, que al final son la “gasolina" de la IA. Eso no solo incrementa el costo, sino que deja menos espacio para contexto en las consultas.

2.4.2. Arquitectura y especificación técnica

TOON toma lo mejor de tres formatos ya conocidos y los mezcla en uno híbrido super optimizado:

- La indentación de YAML para manejar objetos anidados, así evitas las llaves y sus delimitadores.
- El estilo tabular de CSV para arrays de objetos iguales, donde pones los campos una sola vez arriba y luego las filas con datos.
- Una sintaxis bien limpia que quita comillas, corchetes o paréntesis que no aportan nada al fondo del asunto (GitHub toon-format, 2025).

Para arrays uniformes, la sintaxis básica va así: [N,] {campo1, campo2, campo3...}, con N marcando cuántos elementos hay, seguido de los nombres de campos separados por comas. La figura 3 lo ilustra perfecto más adelante. Esto hace que todo sea directo y ahorre tokens sin perder claridad.

Figura 3

Sintaxis básica de TOON

```
users[3,] {id,nombre,rol}:
1,María Rodríguez,Administrador
2,Pedro Sánchez,Usuario
3,Carlos Pérez,Desarrollador
```

Nota. Este formato representa la misma información que su equivalente JSON, pero utilizando aproximadamente 40-60% menos tokens, dependiendo de la estructura de datos. Fuente: Elaboración propia (2025).

Los campos quedan definidos una sola vez en el encabezado, y luego cada fila contiene únicamente los valores. Ahí está el punto fuerte de TOON: Manejar arrays uniformes de objetos donde todos tienen exactamente la misma estructura (GitHub toon-format, 2025).

Cuando los datos se ponen más complejos, TOON recurre a la indentación para marcar las jerarquías como se observa en la figura 4:

Figura 4

Sintaxis TOON para representación de jerarquías

```
metadata:
  version: 1
  author: test
tags[3]: alpha,beta,gamma
```

Nota. Modelo de sintaxis indentada de TOON Fuente: Adaptado de GitHub toon-format (2025).

2.4.3. Benchmarks y rendimiento

Los benchmarks oficiales de TOON, probados con varios LLMs, dejan claro que gana terreno en eficiencia de tokens (GitHub toon-format, 2025). En la tabla 1 se describen los resultados comparativos por cada 1,000 tokens:

Tabla 1

Comparativo de porcentajes de precisión por uso de tokens entre formatos de serialización de datos

Formato de serialización	% Precisión por 1000 tokens	% Precisión total	Total tokens utilizados
TOON	26,90%	73,90%	2,744
JSON compacto	22,90%	70,70%	3,081
YAML	18,60%	69,00%	3,719
JSON estándar	15,30%	69,70%	4,545
XML	13,00%	67,10%	5,167

Fuente: Adaptado de GitHub toon-format (2025).

Los resultados descritos en la tabla 1, revelan que TOON obtuvo un 73.9% de precisión utilizando un 39.6% menos tokens que JSON estándar. Esto no solo recorta costos, sino que ayuda al LLM a identificar y obtener la información correcta con un poco más de acierto.

Al revisar cien repositorios en GitHub, TOON logra recortar unos 6400 tokens por repositorio en comparación con JSON tradicional. Para calcular lo que eso significa en dinero, se toma la tarifa común de $0.03 por cada 1,000 tokens. Al dividir los 6400 entre 1000 y multiplicas por $0.03, sale un ahorro de $0.19 por llamada, redondeado; si una aplicación realiza 1000 llamadas al mes, son alrededor de $190 menos en la factura (GitHub toon-format, 2025).

2.4.4. Escenarios ideales para TOON

Arrays uniformes de objetos: Perfecto para registros que repiten los mismos campos, como tablas de datos o logs de eventos, en pruebas reales, disminuye hasta un 70% de tokens (Apidog, 2025).

Datos de series temporales: Funciona muy bien con métricas analíticas, datos financieros, o lecturas de IoT que mantienen la estructura fija (GitHub toon-format, 2025).

Respuestas de APIs: Grandes volúmenes de datos REST con formatos predecibles, agilizando las cargas en aplicaciones de IA (Codemotion, 2025).

Fine-tuning de LLMs: En datasets de entrenamiento donde cada token cuenta, reduce overhead y sale más económico el proceso. (Idir, 2025).

2.4.5. Limitaciones documentadas

En estructuras con anidamiento profundo o datos poco uniformes, donde el formato tabular aplica en muy baja medida, JSON compacto resulta más eficiente en términos de tokens (GitHub toon-format, 2025).

Cuando entre el 40% y 60% de los arrays califican para el formato tabular, los ahorros en tokens se ven notablemente reducidos (GitHub toon-format, 2025).

Para tablas planas elementales, el CSV ocupa menos espacio; TOON incorpora un sobrecosto mínimo del 5 al 10% al incluir declaraciones de longitud de array, encabezados de campos y delimitadores de ámbito, elementos que sin embargo elevan la precisión de interpretación por parte de los LLMs (GitHub toon-format, 2025).

En aplicaciones sensibles a la latencia, particularmente con modelos locales o cuantizados como Ollama, JSON compacto puede procesarse con mayor rapidez pese al menor consumo de tokens de TOON (GitHub toon-format, 2025).

2.4.6. Implementaciones y ecosistemas

TOON cuenta con implementaciones oficiales en múltiples lenguajes de programación:

- **TypeScript/JavaScript**: Paquete npm @toon-format/toon con funciones de codificación y decodificación.
- **Python**: Biblioteca python-toon con CLI para conversión entre JSON y TOON (GitHub python-toon, 2025).
- **R**: Paquete CRAN para conversión de data frames y objetos R (CRAN, 2025).

2.5. Automatización de Procesos ETL con Inteligencia Artificial

2.5.1. Contexto de ETL Tradicional vs. ETL impulsado por IA

Los procesos ETL forman el núcleo de la integración de datos en las empresas, al extraer información de fuentes variadas, convertirla en formatos prácticos y cargarla en sistemas para análisis o inteligencia de negocios (Informatica, 2025). Aun así, los enfoques ETL convencionales tropiezan con obstáculos importantes:

Codificación manual intensiva: Cada etapa (fuentes, transformaciones, mapeos) exige programación detallada, lo que toma mucho tiempo y abre la puerta a errores (Appmaster, s.f.).

Inflexibilidad ante cambios de esquema: Si la estructura de los datos fuente varía, los pipelines se caen y toca ajustar las reglas a mano (Databricks Blog, 2025).

Problemas con datos no estructurados: Archivos como PDFs, correos o imágenes no encajan fácilmente, quedando restringido a lo tabular (Bismart, 2025).

Escalabilidad limitada: Los sistemas rígidos basados en reglas no se adaptan bien a volúmenes fluctuantes o nuevos patrones (IBM, s.f.).

El ETL impulsado por IA cambia el juego por completo: Automatiza desde la detección de modificaciones hasta optimizar flujos, pasando de tareas manuales a procesos inteligentes que se ajustan solos. Herramientas como Matillion lo elevan a un nivel autónomo, dejando a los ingenieros libres para enfocarse en innovar (Exomindset, 2024).

2.5.2. Capacidades de IA en cada fase ETL

2.5.2.1. Extracción inteligente.

En la etapa de extracción, la IA aporta avances que van más allá de los conectores convencionales: se adapta automáticamente a fuentes poco habituales como PDFs, correos o formularios web, y estructura los datos sin necesidad de reglas programadas (Domo, 2025).

Los algoritmos de machine learning vigilan las fuentes en busca de cambios estructurales (nuevas columnas), tipos de datos alterados o campos renombrados, y ajustan las reglas de mapeo por sí solos (Data Engineer Academy, 2025).

Además, mediante OCR y visión por computadora, extrae información estructurada de documentos e imágenes con diseños variables, algo que los métodos tradicionales no logran, como en facturas de formatos distintos (Databricks Blog, 2025).

2.5.2.2. Transformación inteligente.

La transformación gana mucho con técnicas de machine learning: los algoritmos estudian patrones de conversiones previas exitosas y los aplican a datos nuevos sin programación adicional (Databricks Blog, 2025).

El procesamiento de lenguaje natural entiende el significado semántico, reconociendo que "customer_name" equivale a "client_name" aunque no coincidan al pie de la letra (Databricks Blog, 2025).

Detecta anomalías, valores faltantes o inconsistencias de forma automática, corrigiendo sin intervención humana, mientras enriquece los datos cruzándolos con fuentes externas o prediciendo lo que falta basado en historiales (Matillion, Data Engineer Academy, 2025).

2.5.2.3. Carga optimizada.

Durante la carga, la IA mejora el rendimiento y la estabilidad: predice cómo dividir y cargar datos en data warehouses o lakes según patrones de consultas habituales (Data Engineer Academy, 2025).

Ajusta los flujos en tiempo real para manejar picos de volumen sin afectar la velocidad, y activa "self-healing" para identificar fallos en el pipeline y corregirlos automáticamente, lo que aumenta la resistencia y baja los costos operativos (Matillion, 2025).

2.5.3. Herramientas ETL con IA del mercado

El panorama de herramientas ETL con inteligencia artificial ha avanzado bastante y cubre distintas necesidades según el tamaño y tipo de organización (Integrate.io, 2025).

2.5.3.1. Informática Cloud Data Integration.

Esta plataforma para gestión de datos en la nube usa el motor CLAIRE, que aprovecha metadatos, linaje de datos y monitoreo para generar insights automáticos. Brilla en entornos empresariales grandes y complejos gracias a sus fortalezas en catalogación, seguimiento de linaje y gobernanza de datos (Integrate.io, 2025).

2.5.3.2. Airbyte.

Se trata de una herramienta de código abierto que automatiza flujos de ingeniería de datos con IA, incluyendo la creación automática de conectores basada en especificaciones de API e inferencia de mapeos de campos (Integrate.io, 2025).

2.5.3.3. Fivetran.

Plataforma sin código que traslada datos a data warehouses y lakes en tiempo casi real, con conectores gestionados, transformaciones en SQL, alertas y orquestación que requieren poco mantenimiento (Integrate.io, 2025).

2.5.3.4. AWS Glue.

Servicio serverless de AWS para ETL, basado en Spark, con Glue Studio/Workflows y un catálogo central de datos. Destaca por descubrir esquemas automáticamente y generar scripts ETL mediante machine learning (Integrate.io, 2025)..

2.5.3.5. Matillion.

Incorpora "Maia", un equipo agéntico de datos que no solo ayuda, sino que construye, optimiza y mantiene pipelines de forma autónoma, marcando el nivel más alto en ingeniería de datos con agentes (Matillion, 2025).

2.5.4. Aplicaciones empresariales reales

Las soluciones ETL con IA ya muestran resultados concretos en varios sectores:

Banca y Finanzas: Las entidades financieras automatizan el manejo de datos transaccionales, de clientes, mercados y regulaciones. La IA detecta fraudes en tiempo real al

analizar patrones, y consolida fuentes variadas para gestionar riesgos pese a diferencias en frecuencias y formatos (Databricks Blog, 2025).

Retail y Comercio Electrónico: Alinean datos de compras, productos y comportamiento para personalizar experiencias y afinar pronósticos de demanda (Domo, 2025).

Marketing y Ventas: Combinan CRM, web y campañas en pipelines automáticos para modelos de atribución y puntuación de leads sin preparación manual extensa (Domo, 2025).

Salud: Extraen datos de pacientes de EHR, laboratorios y notas no estructuradas, elevando la precisión en reportes clínicos y análisis poblacionales (Domo, 2025).

2.5.5. Tendencias emergentes

El panorama de ETL moderno está siendo remodelado por varias tendencias convergentes (IBM, s.f.):

2.5.5.1. Plataformas low-code/no-code con IA.

Herramientas que permiten a usuarios de negocio y científicos de datos diseñar y desplegar pipelines con codificación manual mínima, acelerando tiempo a valor (IBM, s.f.).

2.5.5.2. IA para optimización de workflows.

Modelos de IA optimizan flujos de trabajo de datos, predicen fallos de pipelines, automatizan recuperación y mejoran calidad mediante detección de anomalías (IBM, s.f.).

2.5.5.3. Integración estrecha con workflows de ML.

ETL moderno se integra estrechamente con flujos de trabajo de machine learning, habilitando entrenamiento, validación y despliegue más rápidos de modelos (IBM, s.f.).

2.5.5.4. Arquitecturas serverless.

Arquitecturas que reducen overhead de gestión de infraestructura y permiten que procesos ETL escalen automáticamente basándose en volúmenes de datos y cargas de trabajo (IBM, s.f.).

3. Metodología

3.1. Tipo de investigación

Esta investigación se clasifica como documental según su fuente de datos, ya que se basa en análisis de documentación técnica, manuales oficiales y reportes de benchmarks existentes (Ordoñez-Pacheco, 2025). Como explica ATLAS.ti (s.f.), este tipo de investigación utiliza documentos como fuente primaria de información para construir conocimiento sobre un fenómeno específico.

3.2. Enfoque metodológico

El enfoque adoptado es cualitativo, caracterizado por la recolección y análisis de información cualitativa cuyo procesamiento se dirige a lograr descripciones detalladas de los fenómenos estudiados (Cauas, s.f.). Según Ordoñez-Pacheco (2025), el hallazgo principal en metodología indica que el orden lógico comienza con la definición del enfoque, seguido por paradigma, tipo, nivel, diseño y métodos de recolección.

Miasesordetesis (2022) señala que el enfoque cualitativo es una manera de ver las cosas dentro de grandes lineamientos conceptuales, surgiendo de corrientes como el constructivismo, fenomenología y estructuralismo.

3.3. Diseño de investigación

El diseño se caracteriza como no experimental de tipo transversal, ya que no se manipulan deliberadamente variables, sino que se observan fenómenos tal como se presentan en su contexto actual, recolectando datos en un momento único. Este tipo de diseño es apropiado cuando se busca comprender características y relaciones sin intervenir en el fenómeno estudiado (Huaire-Inacio, 2019).

3.4. Nivel de investigación

El nivel de la investigación es **descriptivo-exploratorio**:

Descriptivo: Porque busca conocer las propiedades y características de Google Colab, TOON y procesos ETL con IA. Según IdeaScale (2025), el diseño descriptivo permite definir claramente variables, recopilar datos sobre características específicas y describir patrones o relaciones.

Exploratorio: Dado que estudia la integración de estas tecnologías, tema que ha sido poco investigado, sirviendo de fuente para próximas investigaciones.

3.5. Métodos y técnicas de recolección

Análisis documental: Revisión sistemática de documentación oficial, artículos técnicos, especificaciones de formato, benchmarks publicados y manuales de usuario (ATLAS.ti, s.f.).

Investigación bibliográfica: Consulta de fuentes académicas y profesionales sobre ETL, inteligencia artificial, y automatización de datos.

Análisis comparativo: Evaluación de ventajas, limitaciones y casos de uso de diferentes tecnologías mediante comparación de características documentadas.

3.6. Fuentes de Información

Fuentes primarias:

- Documentación oficial de Google Colaboratory.
- Especificación técnica y repositorio GitHub de TOON.
- Benchmarks oficiales publicados por desarrolladores de herramientas.

Fuentes secundarias:

- Artículos técnicos en plataformas especializadas (IBM, Google Cloud).
- Guías y tutoriales en sitios de educación tecnológica.
- Análisis y opiniones de expertos en blogs profesionales.

3.7. Procedimiento de Análisis

1. **Fase de exploración:** Identificación y recopilación de documentación relevante sobre cada tecnología.

2. **Fase de sistematización:** Organización de información según categorías temáticas (características, ventajas, limitaciones, casos de uso).

3. **Fase de análisis:** Evaluación crítica de capacidades, benchmarks y aplicabilidad.

4. **Fase de síntesis:** Integración de hallazgos para responder preguntas de investigación.

5. **Fase de interpretación:** Discusión de implicaciones y elaboración de recomendaciones.

3.8. Limitaciones metodológicas

Temporalidad de la información: Las tecnologías evolucionan rápidamente; la documentación consultada refleja el estado hasta enero de 2026.

Ausencia de experimentación empírica: Como investigación documental, no se realizaron pruebas prácticas de integración, limitando hallazgos a lo reportado en fuentes.

Disponibilidad de fuentes en español: Aunque se priorizaron fuentes en español, algunas referencias técnicas solo existen en inglés, requiriendo traducción e interpretación.

Sesgo de fuentes: Documentación oficial de proveedores puede presentar sesgo favorable hacia sus propias soluciones.

4. Resultados

4.1. Integración de Google Colab y TOON en Automatización ETL con IA

4.1.1. Sinergia Arquitectónica

La combinación de Google Colab y TOON presenta una sinergia arquitectónica poderosa para automatizar procesos ETL con inteligencia artificial:

4.1.1.1. Google Colab como plataforma de desarrollo y ejecución ETL.

Google Colab se posiciona como una plataforma accesible y potente para desarrollar y ejecutar pipelines ETL completos, todo desde un entorno en la nube sin necesidad de configuraciones locales. Proyectos prácticos lo confirman: por ejemplo, informes universitarios muestran cómo se extraen datos, se transforman con Python y Pandas, y se cargan en bases SQL, unificando el flujo ETL en un solo notebook (ESPE, 2024).

En los siguientes ítems se describen algunos casos reales donde se puede observar el uso de Colab en proceso ETL:

Datos financieros y más: En Domestika convierten CSVs en tablas PostgreSQL vía Colab, manejando extracciones de Drive y librerías clave sin complicaciones. (Domestika, 2025).

ETL con Jupyter/Colab: Tutoriales en video detallan flujos completos con Google Drive, desde extracción hasta carga, ideales para bootcamps y prototipos rápidos. (Soy Henry, 2022).

IA y automatización: Colab integra Gemini para generar código ETL desde descripciones simples, depurando y optimizando en tiempo real. (Google Research, 2025).

Esto lo hace ideal para equipos pequeños o pruebas escalables, procesando volúmenes grandes con PySpark sin invertir en hardware.

4.1.1.2. TOON como formato de intercambio optimizado.

TOON puede desempeñar un papel importante en pipelines ETL impulsados por IA al reducir significativamente los costos de tokens cuando los LLMs participan en el proceso. Específicamente:

Reducción de costos en prompts de LLM: Si necesitas que un LLM analice y valide 100 registros en cada ejecución del pipeline, convertir esos datos de JSON a TOON antes de enviarlo al LLM puede reducir el conteo de tokens en 30-60%. Para pipelines que se ejecutan frecuentemente, estos ahorros se acumulan rápidamente.

Mejora de precisión de LLM: Los benchmarks muestran que TOON no solo reduce tokens, sino que también mejora la precisión de comprensión del LLM (73.9% vs 69.7% para JSON) (GitHub toon-format, 2025), lo que se traduce en menos errores en transformaciones automáticas.

Habilitación de contextos más grandes: Al reducir el conteo de tokens, TOON permite incluir más registros de datos dentro de la ventana de contexto del LLM, facilitando análisis y transformaciones sobre conjuntos de datos más amplios sin truncamiento.

4.1.2. Arquitectura de referencia propuesta

Basándose en capacidades documentadas, se propone una arquitectura integrada para ETL automatizado con IA, basada en Colab y TOON, que contemple los siguientes componentes principales:

4.1.2.1. Capa de Extracción.

Colab permite conectar con diversas fuentes de datos, desde APIs REST y bases SQL/NoSQL hasta archivos en Google Drive o AWS S3. Se implementan conectores a medida con bibliotecas Python habituales como requests, boto3 o google-cloud-storage. Para datos no estructurados como PDFs o imágenes, se aplican modelos de IA con OCR y visión por computadora ya disponibles en el entorno.

4.1.2.2. Capa de Transformación Inteligente.

Los datos extraídos se convierten a formato TOON para un procesamiento eficiente por parte de LLMs. A través de la API de Anthropic en Colab, se invoca Claude para tareas como validar la calidad de datos, detectar anomalías por patrones, generar reglas de transformación a partir de ejemplos y mapear campos semánticamente entre esquemas distintos. Luego, se ejecutan las transformaciones con Pandas, PySpark o Dask según el volumen, volviendo al final a JSON para la carga.

4.1.2.3. Capa de Carga y Orquestación.

Los datos procesados se cargan en destinos como BigQuery, data warehouses en la nube o bases relacionales. El Data Science Agent de Colab supervisa el rendimiento del pipeline y propone mejoras. Se incluye registro detallado y seguimiento del linaje de datos, con ejecuciones programadas vía Colab Enterprise.

En la Figura 5 se puede visualizar un ejemplo de la arquitectura propuesta entre Colab, TOON con el uso IA para procesos ETL.

Figura 5.

Arquitectura de referencia Colab – TOON – IA para ETL

Fuente: Elaboración propia asistida por IA

4.1.3. Beneficios Cuantificables de la Integración

La combinación de Colab y TOON en pipelines ETL con IA genera ventajas concretas que se pueden medir.

Reducción de costos operacionales:

Se evitan gastos en infraestructura al aprovechar los recursos gratuitos o accesibles de Colab en la nube. TOON recorta entre 30 a un 60% los costos de APIs de LLMs. Para una app que procesa 1,000 llamadas al mes con 100 registros cada una, el ahorro solo en tokens ronda los $190 mensuales (GitHub toon-format, 2025).

Mejora de eficiencia:

Los pipelines se desarrollan dos veces más rápido con la ayuda de IA en Colab (Google Developers Blog, 2025).

Disminuye el tiempo de codificación manual gracias a transformaciones generadas automáticamente, y se agiliza la depuración con correcciones inteligentes de errores.

Mayor confiabilidad:

TOON eleva la precisión de procesamiento en 4.2 puntos (73.9% frente a 69.7% de JSON) (GitHub toon-format, 2025).

Los pipelines se auto reparan detectando y corrigiendo fallos vía IA, y se adaptan solos a cambios en los esquemas sin tocar código.

4.1.4. Consideraciones y limitaciones

Aunque trae ventajas claras, esta integración tiene aspectos que vale la pena revisar con cuidado.

4.1.4.1. Seguridad y Privacidad.

Los datos que se manejan en Colab quedan por un rato en los servidores de Google. Para información delicada, mejor optar por Colab Enterprise, que incluye controles de seguridad a nivel empresarial. Siempre aplica encriptación tanto en movimiento como en almacenamiento, y anonimiza los datos antes de pasarlos a LLMs externos.

4.1.4.2. Escalabilidad y limitaciones de recursos.

La versión gratuita de Colab corta las sesiones tras 12 horas y tiene topes en recursos. En producción con volúmenes grandes, toca migrar a Colab Enterprise o infraestructura propia. TOON no rinde igual con datos muy anidados o irregulares.

4.1.4.3. Dependencia de conectividad.

Necesitas una conexión a internet sólida para correr los notebooks en Colab.

Mover datos pesados entre servicios en la nube puede generar algo de latencia.

4.1.4.4. Costos de LLM

TOON ayuda a optimizar, pero si usas mucho los LLMs en transformaciones, los gastos se pueden sumar. Hay que equilibrar la automatización con IA contra métodos tradicionales programados.

4.2. Oportunidades de Desarrollo e Integración

4.2.1. Áreas de Investigación y Desarrollo

Se abren varias líneas para avanzar en herramientas que unan Colab, TOON e IA en procesos ETL automatizados como las descritas a continuación:

4.2.1.1. Framework ETL-AI Unificado.

Una biblioteca Python podría juntar prácticas probadas de ETL con IA: Conectores ya armados para Colab, transformadores que metan TOON donde hace sentido, un manejador de LLMs que decida el formato según los datos y caché para no repetir llamadas innecesarias a APIs.

4.2.1.2. Herramienta de Conversión Automática JSON-TOON.

El analizador revisaría JSONs, mediría qué tan aptos son los arrays para formato tabular, cambiaría solo lo que vale la pena a TOON y sacaría reportes con ahorros de tokens y costos proyectados.

4.2.1.3. Plugin de Colab para ETL visual.

La extensión daría una interfaz visual intuitiva de arrastrar y soltar para armar pipelines, generaría código Python afinado automáticamente, enlazaría con Google Cloud y seguiría el rendimiento junto a gastos en tokens al instante.

4.2.1.4. Agente Autónomo de ETL.

Un agente IA escanearía fuentes y destinos, plantearía diseños óptimos de pipeline, armaría el código ETL completo con manejo de fallos y vigilaría en producción, corrigiendo transformaciones sobre la marcha.

4.3. Integración con ecosistema de herramientas

Enlazar Colab y TOON con plataformas establecidas como las descritas a continuación, multiplica su potencial:

4.3.1. Integración con Airflow

Airflow se lleva el primer lugar en orquestación de datos. Con Colab, los notebooks entran como tareas en DAGs; usas su programación y manejo de dependencias, los mantienes en Git y ejecutas versiones parametrizadas mediante Papermill (Apache Airflow, 2025)..

4.3.2. Integración con dbt (data build tool)

Dbt se encarga de la transformación directamente en data warehouses modernos como BigQuery o Snowflake. Junto con Colab, crean flujos que transitan suavemente de los prototipos a producción. Se puede experimentar primero con Pandas antes de pasar a SQL puro, ejecutar tests mediante “!dbt run para obtener reportes al instante, dejar que Gemini genere modelos dbt completos desde instrucciones simples como "agrega ventas por región", y sincronizar todo con GitHub y dbt Cloud para que las pruebas coincidan exactamente con el entorno real (Google Cloud, s.f.). Esta combinación elimina barreras entre data scientists y analytics engineers, acelerando el ciclo completo ETL/ELT.

4.3.3. Integración con Great Expectations

Para chequear datos en Colab, Great Expectations se instala fácil con !pip, arma contextos y valida DataFrames de Pandas o Spark, mostrando reportes HTML al momento (Paradigma Digital, 2023).

El profiler saca reglas de historiales sobre nulos o rangos; los checkpoints paran anomalías y se enganchan a Airflow o GitHub Actions para CI/CD que bloquea datos sucios antes de ir a producción (Datacamp, 2024). Logras datos sólidos desde el principio, todo visible en el notebook.

4.4. Aplicaciones Avanzadas de IA

Las siguientes propuestas de IA, llevan los procesos ETL mucho más allá de lo actual:

4.4.1. Transfer Learning para Mapeo de Schemas

Modelos entrenados con historiales de mapeos reconocen campos equivalentes automáticamente, "cliente_id" en una fuente pasa a ser "id_usuario" en otra, y sugieren uniones precisas junto con transformaciones complejas basadas en patrones pasados. Así resuelve variaciones locales de nombres que complican cualquier regla estática.

4.4.2. Reglas de Calidad Automáticas

La IA examina las distribuciones reales de los datos para crear reglas adaptables: Rangos lógicos para edades (18-99), formatos válidos de email o condiciones como "fecha_fin después de fecha_inicio". Se actualizan solas ante cambios en los patrones, sin revisiones manuales constantes.

4.4.3. Optimización con Refuerzo

El aprendizaje por refuerzo elige en el momento el orden óptimo de operaciones “filtrar antes que agregar”, por ejemplo, decide entre memoria o disco según el tamaño del dataset y calibra el paralelismo para aprovechar al máximo CPUs y GPUs. Los pipelines terminan corriendo hasta tres veces más rápido, sin modificar código..

4.4.4. Documentación por NLP

Analizando código Python o SQL, la IA produce descripciones en español de cada paso (agrupa ventas por región y saca el ticket promedio), genera diagramas de linaje de forma automática y explica la lógica de negocio detrás. Olvídate de wikis que nadie actualiza.

Con estas funciones, ETL deja de ser un cuello de botella costoso para convertirse en herramientas que se optimizan y aprenden por sí mismas.

5. Discusión

5.1. Interpretación de hallazgos

Los resultados muestran que Google Colab y TOON, pese a sus orígenes distintos, se unen de forma efectiva para resolver retos clave en la automatización de ETL con IA. Colab democratiza el acceso a potencia computacional, quitando obstáculos económicos y técnicos que antes frenaban pipelines avanzados. Resulta ideal para usuarios de cualquier nivel, sobre todo en Latinoamérica donde la infraestructura escasea a menudo.

TOON, por su parte, optimiza costos al reducir tokens en un 39,6% sin perder precisión (GitHub toon-format, 2025). Ese ahorro (como los $190 al mes en 1.000 llamadas) crece con el volumen y marca la diferencia entre proyectos viables o no. Más allá de números, la IA transforma ETL de raíz; pasa de tareas manuales a sistemas que aprenden y se adaptan, elevando a los ingenieros de simples programadores en arquitectos de sistemas inteligentes.

5.2. Contraste con literatura existente

Los hallazgos encajan con tendencias actuales de IBM (s.f.), como nubes, streaming y automatización, pero suman una capa de LLMs. Complementa herramientas clásicas como Informática o DataStage, ideal para prototipos o presupuestos ajustados. Frente al ETL rígido de reglas manuales, esta vía aporta adaptabilidad con sus pros, como respuestas automáticas, y contras, como menor transparencia en auditorías.

5.3. Implicaciones prácticas

5.3.1. Para organizaciones pequeñas y medianas

La unión de Colab, TOON e IA pone al alcance de startups y PYMEs herramientas ETL avanzadas, antes exclusivas de grandes empresas. Así pueden armar pipelines complejos sin gastar fortunas en infraestructura desde el arranque.

5.3.2. Para instituciones educativas

Colab simplifica la enseñanza de ETL y machine learning, ya que los estudiantes evitan pelear con instalaciones complicadas, es decir, permite centrarse en algoritmos y técnicas, no en configuraciones tediosas.

5.3.3. Para científicos de datos e investigadores

Ofrece un entorno único para todo el ciclo: desde explorar datos hasta entrenar modelos, sin saltar entre plataformas. The Machine Learners (s.f.) subraya cómo entrenar deep learning con tecnología top y gratis cambia las reglas del juego en investigación.

5.3.4. Para empresas con datos sensibles

Las fallas de seguridad de Colab exigen revisar bien antes de usarlo. Colab Enterprise, con sus controles corporativos, sale como opción sólida, aunque suma costos que hay que considerar en el análisis del retorno de la inversión.

5.4. Limitaciones del Estudio

Ausencia de validación empírica: Al tratarse de un análisis documental, los resultados provienen de reportes y documentación sin pruebas experimentales directas. Futuros trabajos deberían poner en marcha pipelines ETL reales con la arquitectura planteada, evaluando rendimiento, costos y estabilidad en producción.

Temporalidad acotada: Tanto Google Colab con su giro AI-first en 2025, como TOON, aún reciente, cambian rápido. Estos hallazgos capturan el panorama hasta enero de 2026 y podrían quedar desactualizadas con las evoluciones venideras.

Sesgo de fuentes: La documentación de Google y los creadores de TOON tiende a resaltar lo positivo. Aunque se usaron fuentes externas, la escasez de críticas profundas deja un enfoque menos equilibrado.

Falta de análisis comparativo cuantitativo: No hay pruebas directas contra opciones como AWS Glue, Azure Data Factory o Databricks en métricas claras. Estudios posteriores deberían cerrar ese vacío con benchmarks específicos.

5.5. Contribuciones al Conocimiento

Marco conceptual integrador: Este estudio ofrece el primer marco documentado que une Colab, TOON e IA para automatizar procesos ETL. La arquitectura en tres capas da una base sólida para aplicaciones prácticas.

Síntesis de información dispersa: Reúne datos sobre tecnologías nuevas, antes esparcidos en varias fuentes, para dar una visión completa de sus fortalezas, límites y cómo se potencian entre sí.

Identificación de casos de uso apropiados. Aclara dónde esta integración suma valor real y dónde mejor optar por otras opciones, guiando elecciones tecnológicas con criterio.

Estimaciones económicas preliminares: Presenta cálculos iniciales de ahorros basados en pruebas existentes, listos para confirmarse en escenarios concretos.

5.6. Direcciones futuras de investigación

Validación experimental: Poner en marcha pipelines ETL reales con la arquitectura sugerida, midiendo latencia, volumen de datos, costos totales y fiabilidad frente a métodos clásicos u otros modernos.

Estudios de caso sectoriales: Registrar usos en áreas como salud, finanzas o retail, destacando ajustes locales, obstáculos únicos y ganancias propias de cada campo.

Optimización de TOON: Probar mejoras para datos muy complejos sin perder ahorro en tokens, como mezclas automáticas TOON-JSON según el tipo de información.

IA explicable en ETL: Crear formas de aclarar qué decide un LLM en las transformaciones, clave para revisiones y normas. Incluir registros de su lógica y chequeos humanos puntuales.

Seguridad y privacidad: Profundizar en cómo proteger datos delicados en flujos con Colab (anonimización, cifrado o cómputo seguro). Comparar Colab Enterprise con rivales bajo reglas estrictas.

Benchmarking exhaustivo: Hacer pruebas detalladas de Colab contra Databricks, SageMaker o Azure ML en ETL reales, valorando no solo técnica sino facilidad de uso y herramientas aliadas.

6. Conclusión y recomendaciones

6.1. Síntesis y hallazgos principales

Colab y TOON no nacieron pensando en trabajar juntos, pero casualmente resuelven a la perfección varios dolores de cabeza en automatizar ETL con IA. Lo que empezó como un simple cuaderno en línea ahora tiene agentes inteligentes que escriben código más rápido, detectan errores antes de que se vean y exploran datos sin que les digas cómo. Para ETL significa que cualquiera puede usar poder de cómputo serio sin comprar servidores. Y TOON arregla el problema del JSON que gasta tokens de más, reduce 30-60% sin perder precisión, con ahorros reales de $190 al mes en aplicaciones normales.

6.2. Recomendaciones para Implementación

Basándose en los hallazgos de esta investigación, se proponen las siguientes recomendaciones estratégicas:

6.2.1. Al empezar automatización ETL con IA

Probar primero con Colab gratis. Utilizar TOON cuando los LLMs tengan que trabajar duro. Armar conectores que sirvan para varios proyectos. Medir bien cuánto ahorras en tiempo y tokens.

6.2.2. Si ya se tiene procesos ETL automatizados en marcha

Ir migrando poco a poco a mezclas con Colab. Considerar la versión Enterprise si se manejan datos sensibles. Crear un sistema que escoja el formato correcto automáticamente.

6.2.3. Para desarrolladores de herramientas ETL

Incluir TOON desde el principio. Hacer plugins para Colab. Simplifica cómo se conectan con LLMs. Colabora en proyectos open source.

6.3. Reflexión Final

Plataformas al alcance como Google Colab, junto con formatos prácticos tipo TOON y los Modelos de Lenguaje Grande que avanzan sin parar, están dando un giro completo al manejo de datos en cualquier empresa.

Los procesos ETL que siempre pidieron horas de trabajo a mano y estaban plagados de errores, ahora mutan hacia sistemas que se las ingenian solos para adaptarse y afinarse con el tiempo.

Lejos de dejar sin trabajo a los ingenieros de datos, esto los lleva a un nivel superior: Dejan de seguir instrucciones fijas para montar estructuras que piensan por sí mismas.

No se trata de que la IA lo haga todo, sino de un equipo mixto donde las máquinas toman las tareas mecánicas y las personas nos quedamos con lo importante: estrategias, diseños bien pensados y resolver enredos serios.

Las compañías que adopten estas tecnologías desde ahora, y preparen a su gente para ETL con IA, van a despegar en innovación, datos sólidos y gastos más bajos. Claro que la tecnología por sí sola no basta; se necesita un ambiente que aliente a experimentar, seguir aprendiendo y unir fuerzas entre los que saben de datos, ciencia y el negocio en sí.

Referencias

Abelo Lab. (2024). *Desafíos de los ETL en la integración de datos*. https://abelolab.com/desafios-de-los-etl-en-la-integracion-de-datos-abordando-las-complejidades-del-flujo-de-datos/

Alice Biometrics. (2024). *ETL para sistemas basados en IA de verificación de identidad*. https://alicebiometrics.com/etl-para-sistemas-basados-en-ia-de-verificacion-de-identidad/

Analytics Vidhya. (2024). *A comprehensive guide to Google Colab*. https://www.analyticsvidhya.com/blog/2020/03/google-colab-machine-learning-deep-learning/

Apache Airflow. (2025). *Papermill Operator documentation*. https://airflow.apache.org/docs/apache-airflow-providers-papermill/stable/operators.html

Apidog. (2025). *TOON vs JSON en LLMs: ¿Qué es y reemplazará a JSON?.* https://apidog.com/es/blog/toon-vs-json-for-llms-es/

AppMaster. (s.f.). *Herramientas ETL sin código: Todo lo que quieres saber.* https://appmaster.io/es/blog/herramientas-etl-sin-codigo

ATLAS.ti. (s.f.). Análisis de documentos - Cómo analizar datos textuales para la investigación. https://acortar.link/cmuR02

Bismart. (2025). *ETL, ELT y Más Allá: 5 Tendencias Clave en Integración de Datos 2025***.** https://blog.bismart.com/tendencias-etl-elt-integracion-datos

CodeMotion Magazine. (2025). *La ineficiencia oculta de JSON frente a la revolución de TOON*. https://www.codemotion.com/magazine/es/inteligencia-artificial/la-ineficiencia-oculta-de-json-frente-a-la-revolucion-de-toon/

CRAN. (2025). *toon: Token-Oriented Object Notation (TOON) for R*. https://cran.r-project.org/web/packages/toon/index.html

Data Engineer Academy. (2025). *Automating ETL with AI*. https://dataengineeracademy.com/blog/automating-etl-with-ai/

Databricks Blog. (2025). *AI ETL: How Artificial Intelligence Automates Data Pipelines.* https://www.databricks.com/blog/ai-etl-how-artificial-intelligence-automates-data-pipelines

DataCamp. (2024). *Tutorial Great Expectations: Validar datos con Python.* https://www.datacamp.com/es/tutorial/great-expectations-tutorial

Domestika. (2025). *Prueba de ETL con Python de Google Colab a PostgreSQL.* https://www.domestika.org/es/projects/1839052-prueba-de-etl-con-python-de-google-colab-a-postgresql

Domo. (2025). *The future of AI ETL: Smarter pipelines, benefits & real-world examples*. https://www.domo.com/learn/article/future-of-ai-et

Exomindset. (2024, 11 de julio). *Matillion: La herramienta para la integración de datos en la nube.* https://exomindset.co/es/matillion-la-herramienta-para-la-integracion-de-datos-en-la-nube/

Geekflare. (2025). *Google Colab: Qué, cómo y características*. https://geekflare.com/dev/google-colab/

GitHub toon-format. (2025). *TOON format specification and benchmarks*. https://github.com/toon-format/toon

Google Cloud. (s.f.). ¿Qué es ETL?. https://cloud.google.com/learn/what-is-etl?hl=es

Google Cloud. (s.f.). *Documentación de Colab Enterprise*. https://docs.cloud.google.com/colab/docs?hl=es

Google Cloud. (s.f.). *Introducción a Colab Enterprise.* https://cloud.google.com/colab/docs/introduction?hl=es

Google Cloud. (s.f.). *Usa BigQuery DataFrames en dbt*. https://docs.cloud.google.com/bigquery/docs/dataframes-dbt

Google Colab. (s.f.). *Preguntas frecuentes*. https://research.google.com/colaboratory/faq.html

Google Developers Blog. (2025). *Fully Reimagined: AI-First Google Colab*. https://developers.googleblog.com/fully-reimagined-ai-first-google-colab/

Google for Developers. (2025). *Colab release notes*. https://developers.google.com/colab/release-notes

Google Research. (s.f.). *Funciones y capacidades*. https://colab.research.google.com/?utm_source=scs-index

Huaire-Inacio, EdsonJ. (2019). *Método de investigación. Material de clase.* https://www.aacademica.org/edson.jorge.huaire.inacio/35.pdf

IBM. (s.f.). *¿Qué es la IA de documentos*?. https://www.ibm.com/mx-es/think/topics/document-ai

IBM. (s.f.). *¿Qué es ETL (extracción, transformación, carga)*?. https://www.ibm.com/es-es/topics/etl

IdeaScale. (2025). *¿Qué es un diseño de investigación? Definición, tipos, métodos y ejemplos.* https://ideascale.com/es/blogs/que-es-el-diseno-de-la-investigacion/

IDir.ai. (2025). *TOON vs JSON: Reduce tus costos de tokens de IA en un 30%.* https://idir.ai/es/blog/toon-vs-json-reduce-tus-costos-de-tokens-de-ia-en-un-30

InfoQ. (2025). *New Token-Oriented Object Notation (TOON) hopes to cut LLM costs by reducing token consumption.* https://www.infoq.com/news/2025/11/toon-reduce-llm-cost-tokens/

Informatica. (2025). *ETL (Extract, Transform, Load) explained*. https://www.informatica.com/resources/articles/what-is-etl.html

Integrate.io. (2025). *Top AI ETL Tools: Revolutionizing Data Engineering*. https://www.integrate.io/blog/ai-etl-tools/

Integrate.io. (2026). *AI-powered ETL market projections — 35 statistics every data leader should know in 2026.* https://www.integrate.io/blog/ai-powered-etl-market-projections/

Matillion. (2025). The *10 best AI ETL Tools*. https://www.matillion.com/learn/blog/best-ai-etl-tools

Miasesordetesis. (2022).*Enfoque, tipo, diseño y método de investigación.* https://miasesordetesis.com/enfoque-tipo-diseno-metodo-de-investigacion/

Ordoñez-Pacheco, Ángel F. (2025). *Metodología de la Investigación Metodología académica con aplicación a las investigaciones sociales: enfoques, tipos, métodos y diseños. Sociedad & Tecnología*, 8(2), 335–357. https://doi.org/10.51247/st.v8i2.484

Paradigma Digital. (2023*). Great Expectations: Librería para maximizar calidad de datos.* https://www.paradigmadigital.com/dev/great-expectations-libreria-maximizar-calidad-datos/

Paradigma Digital. (2023). *Tutorial Great Expectations en Colab*. [Video]. Youtube. https://www.youtube.com/watch?v=vx3GearKZuE

Skyone Solutions. (2025, 16 de enero). *ETL e IA: cómo este dúo puede impulsar su proyecto de datos.* https://skyone.solutions/es/blog/datos/proyectos-de-datos-etl-ia/

Soy Henry. (2022). ETL con Jupyter Notebook y Google Drive en Colab. [Video]. Youtube. https://www.youtube.com/watch?v=oMUfQsOVToI

Tecnología BI. (2025). *Cómo automatizar procesos ETL con las herramientas más populares.* https://tecnologiabi.com/como-automatizar-procesos-etl/

The Machine Learners. (s.f.) *Google Colab – Cómo utilizarlo*. https://www.themachinelearners.com/introduccion-google-colab/

Universidad de las Fuerzas Armadas ESPE. (2024). Informe laboratorio ETL con Python en Google Colab. https://www.studocu.com/ec/document/universidad-de-las-fuerzas-armadas-de-ecuador/modelado-de-datos/grupo-01-informe-laboratorio-3-etl-con-python-nrc-8455

Glosario de términos

Agente Agéntico: Sistema de IA capaz de actuar de forma autónoma para lograr objetivos sin requerir instrucciones paso a paso del usuario.

APIs (Application Programming Interfaces): Conjunto de protocolos, herramientas y definiciones que permiten que diferentes aplicaciones de software se comuniquen entre sí. Las APIs definen los métodos y formatos de datos que las aplicaciones pueden usar para solicitar e intercambiar información, actuando como intermediarios que facilitan la integración entre sistemas diversos.

Arrays: Estructuras de datos que almacenan colecciones ordenadas de elementos del mismo tipo, accesibles mediante índices numéricos. En programación, los arrays permiten organizar múltiples valores relacionados en una única variable, facilitando operaciones como iteración, búsqueda y manipulación de conjuntos de datos.

BigQuery: Data warehouse completamente administrado de Google Cloud para análisis de grandes conjuntos de datos usando SQL.

ETL (Extract, Transform, Load): Proceso de integración de datos que consiste en extraer datos de fuentes diversas, transformarlos a formatos utilizables, y cargarlos en sistemas de destino.

Fine-tuning: Proceso de ajustar un modelo de machine learning pre-entrenado utilizando un conjunto de datos específico para especializarlo en una tarea particular. Esta técnica aprovecha el conocimiento general adquirido durante el entrenamiento inicial y lo refina para mejorar el rendimiento en aplicaciones o dominios específicos.

Frameworks: Estructuras de software que proporcionan una base estandarizada para desarrollar aplicaciones. Los frameworks incluyen bibliotecas de código, herramientas y convenciones que facilitan el desarrollo al ofrecer funcionalidades comunes preconstruidas, permitiendo a los desarrolladores enfocarse en la lógica específica de la aplicación en lugar de implementar funcionalidades básicas desde cero.

GitHub: Plataforma de alojamiento de código basada en la web que utiliza el sistema de control de versiones Git. GitHub permite a los desarrolladores colaborar en proyectos de software, gestionar versiones de código, realizar seguimiento de cambios, revisar código mediante pull requests, y compartir proyectos de código abierto con la comunidad global de desarrolladores.

GPU (Graphics Processing Unit): Unidad de procesamiento especializada originalmente diseñada para procesamiento gráfico, ampliamente utilizada para entrenar modelos de machine learning.

Insights: Conocimientos profundos o comprensiones valiosas derivadas del análisis de datos. Los insights van más allá de la simple información para revelar patrones, tendencias o relaciones significativas que pueden informar decisiones estratégicas y acciones concretas en contextos empresariales o de investigación.

IoT (Internet of Things): Red de dispositivos físicos interconectados equipados con sensores, software y conectividad de red que les permite recopilar, intercambiar y actuar sobre datos. Los dispositivos IoT van desde electrodomésticos inteligentes hasta sensores industriales, creando ecosistemas donde objetos físicos pueden comunicarse y ser controlados remotamente.

Latencia: Tiempo de retraso entre el momento en que se inicia una solicitud o acción y el momento en que se completa o se recibe una respuesta. En sistemas de datos y redes, la

latencia baja es crítica para aplicaciones en tiempo real, mientras que latencia alta puede afectar negativamente la experiencia del usuario y la eficiencia operacional.

LLM (Large Language Model): Modelo de inteligencia artificial entrenado en grandes cantidades de texto capaz de comprender y generar lenguaje natural.

Logs: Registros cronológicos de eventos, acciones o transacciones generados por sistemas de software, aplicaciones o dispositivos. Los logs documentan actividades del sistema, errores, advertencias y mensajes informativos, siendo esenciales para depuración, monitoreo de rendimiento, auditoría de seguridad y análisis de comportamiento de sistemas.

Overhead: Recursos computacionales adicionales (tiempo de procesamiento, memoria, almacenamiento o ancho de banda) requeridos para realizar operaciones auxiliares que no contribuyen directamente a la tarea principal. El overhead puede incluir gestión de memoria, comunicación entre procesos, serialización de datos o mantenimiento de estructuras de datos, y su minimización es importante para optimizar el rendimiento del sistema.

Pipeline: Secuencia automatizada de pasos de procesamiento de datos desde fuente hasta destino.

Plugin: Componente de software modular que añade funcionalidades específicas a una aplicación o plataforma existente sin modificar su código base. Los plugins permiten extender capacidades de software de forma flexible, habilitando personalización y especialización según necesidades particulares mientras mantienen la separación entre funcionalidad core y extensiones.

RESTful: Estilo arquitectónico para diseñar servicios web que adhiere a los principios de REST (Representational State Transfer). Las APIs RESTful utilizan métodos HTTP estándar (GET, POST, PUT, DELETE) para realizar operaciones sobre recursos identificados por URLs, enfatizando la comunicación sin estado, cacheable y basada en estándares web abiertos.

Runtimes: Entornos de ejecución que proporcionan los recursos necesarios para ejecutar programas o aplicaciones. Un runtime incluye bibliotecas, servicios del sistema operativo, gestión de memoria y otros componentes esenciales que traducen código de alto nivel a instrucciones ejecutables por el hardware, gestionando la ejecución del programa durante su ciclo de vida.

Schema: Estructura organizativa que define cómo se almacenan los datos, incluyendo tipos de datos, relaciones y restricciones.

Scope: Ámbito o alcance que define la visibilidad y accesibilidad de variables, funciones u objetos dentro de un programa. En programación, el scope determina dónde pueden ser referenciados ciertos elementos del código, controlando la organización y prevención de conflictos de nombres. En contexto de proyectos, scope refiere al conjunto de objetivos, entregables y límites definidos para una iniciativa.

Self-healing: Capacidad de un sistema para detectar y corregir automáticamente fallos sin intervención humana.

Serialización de datos: Proceso de convertir estructuras de datos u objetos en un formato que puede ser almacenado o transmitido y posteriormente reconstruido. La serialización transforma datos de estructuras complejas en memoria a formatos lineales como JSON, XML o binarios, permitiendo persistencia en disco, transmisión por red o intercambio entre diferentes sistemas y lenguajes de programación.

Token: Unidad básica de texto procesada por Modelos de Lenguaje Grande (LLMs), típicamente palabras o sub-palabras.

TPU (Tensor Processing Unit): Procesador especializado diseñado por Google específicamente para acelerar cargas de trabajo de machine learning.

YAML (YAML Ain't Markup Language): Formato de serialización de datos legible por humanos que utiliza indentación y estructura jerárquica para representar información. YAML es comúnmente usado para archivos de configuración, intercambio de datos entre lenguajes de programación y definición de pipelines CI/CD, ofreciendo sintaxis más limpia y concisa que XML o JSON para muchos casos de uso.