ri**Fecha:** 10 de marzo de 2026
Responsables: Juan Diego Mejía
Estado: Análisis de Rentabilidad y Herramientas

🛠️ Glosario de Tecnologías Core

Para entender la eficiencia de este proyecto, es fundamental definir las tres tecnologías que permiten el procesamiento masivo con bajo presupuesto:

1. n8n (El Orquestador)

n8n es una herramienta de automatización de flujos de trabajo de código abierto (self-hosted).

- **Su función:** Actúa como el "cerebro" o director de orquesta. Es el encargado de recibir los 100,000 registros, decidir qué IA debe procesarlos y finalmente guardarlos en la base de datos.
- **Por qué se usa:** A diferencia de otras herramientas como Zapier, al instalarlo en tu propio servidor no pagas por cada registro procesado, lo que reduce el costo operativo de cientos de dólares a **$0**.

2. Llama 4 (La IA Privada y Local)

Llama 4 es un modelo de lenguaje de gran tamaño (LLM) desarrollado por Meta, diseñado para ser ejecutado de forma local.

- **Su función:** Actúa como la "IA Guardiana". Se encarga exclusivamente de procesar los datos sensibles (nombres, teléfonos, documentos).
- **Por qué se usa:** Al correr dentro de tu propio servidor (vía **Ollama**), los datos confidenciales nunca viajan por internet ni pasan por servidores de terceros. Esto garantiza privacidad absoluta y un costo de **$0 por token**.

3. Google Gemini (La IA de Gran Escala)

Gemini es la familia de modelos de IA más avanzados de Google, conocida por su capacidad de procesar volúmenes masivos de información.

- **Su función:** Actúa como la "IA de Volumen". En su versión **2.5 Flash-Lite**, se encarga de la limpieza pesada, la normalización de texto y la detección de duplicados en todo el conjunto de datos.
- **Por qué se usa:** Su "ventana de contexto" (capacidad de memoria) de 1 millón de tokens le permite analizar miles de filas al mismo tiempo, algo que otras IAs no pueden hacer. Es

la opción más económica y veloz del mercado en la nube para procesamiento masivo.

1. Resumen Ejecutivo: Proyecto IA Dataflow

El proyecto **IA Dataflow** implementa una arquitectura híbrida de vanguardia para procesar **100,000 registros**, priorizando la soberanía de datos y la eficiencia económica extrema mediante el uso coordinado de IA en la nube y local.

1.1. Ecosistema de IA Seleccionado

Basado en la documentación técnica de marzo de 2026, hemos asignado roles específicos a cada modelo:

- **IA de Volumen (Gemini 2.5 Flash-Lite):** * *Función:* Limpieza estructural y deduplicación masiva.
  - *Ventaja:* Ventana de contexto de 1M de tokens y el costo más bajo del mercado. Ideal para comparar la fila 10 con la 90,000.
- **IA Guardiana (Llama 4 - 8B Local):** * *Función:* Anonimización de datos sensibles (PII).
  - *Ventaja:* Ejecución 100% local en VPS (Costo $0 por token). Privacidad absoluta.
- **IAs de Comparativa (Backup):**
  - *GPT-4o mini:* Para validaciones rápidas de formato.
  - *Claude 3.5 Haiku:* Para casos de ambigüedad semántica compleja.

---

2. Desglose de Costos (Marzo 2026)

Cálculo para 100k registros aplicando Tarifa Batch (50% desc.) y compresión TOON.

Proveedor	Modelo	Entrada (1M)	Salida (1M)	Costo 100k Reg.	Estatus
Google	**Gemini 2.5 Flash-Lite**	**$0.05**	**$0.20**	**$11.25 USD**	**SELECCIONADA**
Meta	**Llama 4 (Ollama)**	**$0.00**	**$0.00**	**$0.00 USD**	**SELECCIONADA**
OpenAI	GPT-4o mini	$0.075	$0.30	$15.00 USD	Alternativa
Google	Gemini 3.1 Flash-Lite	$0.125	$0.75	$31.25 USD	Descartada
Anthropic	Claude 3.5 Haiku	$0.40	$2.00	$90.00 USD	Descartada

3. Arquitectura e Infraestructura

Para orquestar este flujo, se utilizan herramientas que eliminan costos por ejecución y maximizan el control.

Componentes Clave

- **n8n Self-Hosted:** El "Cerebro Operativo". Conecta archivos, IAs y bases de datos sin costo por tarea.
- **Estándar TOON:** Algoritmo de compresión de texto que ahorra hasta un 45% en el gasto de tokens.
- **VPS (Servidor Dedicado):** Aloja n8n, PostgreSQL y Llama 4 por un costo fijo de **$15 USD/mes**.

Flujo Técnico Paso a Paso

1. **Ingesta:** n8n recibe los datos crudos vía Webhook o archivo.
2. **Filtro Local (Llama 4):** Se enmascaran datos sensibles para cumplir con normativas de privacidad.
3. **Compresión (TOON):** Se reduce el volumen de texto antes de enviarlo a la nube.
4. **Limpieza Masiva (Gemini):** Normalización y eliminación de duplicados globales.
5. **Carga:** Inserción en bloque (Bulk Insert) en **PostgreSQL**.

---

4. Diferencias Técnicas: Nube vs. Local

Característica	Google Gemini (Nube)	Llama 4 + Ollama (Local)
API Key	Requerida (Facturación)	No necesaria
Costo	Pago por uso (tokens)	Gratis (Consumo de VPS)
Privacidad	Datos viajan a Google	Datos nunca salen del servidor
Conexión en n8n	Nodo Gemini + API Key	Nodo Ollama + URL Local

> **Nota Técnica:** Para activar Llama 4 en el servidor, se utiliza el comando terminal `ollama pull llama4:8b`, permitiendo que n8n lo reconozca automáticamente.

---

5. Estrategias de Optimización Avanzada

1. **Bulk Insert (PostgreSQL):** En lugar de 100,000 operaciones de guardado, se agrupan en bloques de 5,000 para reducir el tiempo de 10 minutos a 30 segundos.
2. **Context Caching:** Gemini permite "congelar" instrucciones de limpieza pesadas para no pagar por ellas en cada petición.
3. **Split In Batches (n8n):** Divide el proceso en mini-lotes para evitar que la memoria RAM de 4GB colapse.
4. **Idempotencia (Upsert):** Uso de la función "Insert or Update" para evitar duplicados si el proceso debe reiniciarse tras un fallo.

---

6. Validación y Enlaces Oficiales

- Tarifas Gemini 2.5 Flash-Lite
- Documentación Batch API (50% desc.)
- Precios OpenAI
- **Anthropic Pricing:** anthropic.com/pricing

⏳ Jerarquía de Control en IA Dataflow

Para que el procesamiento de 100k registros sea exitoso, cada nivel debe cumplir una función específica:

1. El Prompt (La Orden Operativa)

Es la unidad mínima de acción. Es el "qué" debe hacer la IA en este preciso segundo con un dato específico.

- **Ejemplo en tu proyecto:** "Toma esta lista de 100 filas y elimina los registros donde el correo electrónico sea idéntico. Devuelve solo los registros únicos en formato JSON".
- **Utilidad:** Es ejecución pura. Se usa en el nodo de Gemini o Llama 4 dentro de n8n para procesar el lote actual.

2. Instrucciones (El Manual de Procedimiento)

Es el "cómo" debe trabajar la IA siempre, independientemente del dato que reciba. Define las reglas de negocio y el comportamiento.

- **Ejemplo en tu proyecto:** "Para eliminar duplicados, prioriza siempre el registro que tenga la fecha de actualización más reciente. Si dos registros tienen el mismo ID pero distinto teléfono, marca ambos para revisión humana".

- **Utilidad:** Garantiza que la IA no tome decisiones arbitrarias y mantenga la integridad de tu base de datos PostgreSQL.

3. Skills / Habilidades (La Caja de Herramientas)

Es un entrenamiento o capacidad técnica específica que se le otorga a la IA para que pueda interactuar con el mundo exterior o realizar tareas técnicas.

- **Ejemplo en tu proyecto:** Una skill de **"Normalización de Direcciones"**. El agente sabe usar la API de Google Maps para convertir "Av. Siempre Viva 123" en una coordenada geográfica real.
- **Utilidad:** Permite que la IA haga cosas que un modelo de lenguaje por sí solo hace mal (como cálculos matemáticos exactos o validaciones de sintaxis de código).

4. Agentes (El Especialista)

Es la entidad superior. Un Agente es un rol que agrupa múltiples habilidades y sigue instrucciones complejas para cumplir un objetivo de alto nivel.

- **Ejemplo en tu proyecto: "Agente de Calidad de Datos (Data QA)"**.
  - **Instrucción:** Asegurar que los datos que llegan a Power BI sean perfectos.
  - **Skills:** SQL (para consultar la DB), Validación de JSON, Detección de anomalías.
- **Utilidad:** Los agentes pueden trabajar en cadena. Un agente limpia, otro anonimiza y un tercero audita.

📊 Comparativa de Roles en tu Arquitectura

Concepto	Representación	Aplicación en IA Dataflow
Prompt	El Martillo	"Golpea este clavo (registro) ahora".
Instrucción	El Plano	"Los clavos deben ir cada 10cm y siempre rectos".
Skill	El Conocimiento	Saber usar un martillo neumático o una sierra láser.
Agente	El Carpintero	El profesional que sabe construir el mueble completo usando todo lo anterior.

💡 ¿Cómo se ve esto en la práctica?

Si quieres organizar tus tablas de forma eficiente, podrías configurar un **Agente de Estructuración**:

1. **Instrucción:** "Eres un DBA (Administrador de Base de Datos). Tu objetivo es organizar tablas bajo la 3ra forma normal".
2. **Skill:** Capacidad de generar y ejecutar sentencias SQL en tu PostgreSQL.
3. **Prompt:** "Analiza estos datos de ventas y crea la tabla de 'Clientes' y la de 'Pedidos' vinculadas por un ID único".