📋 **Resumen del Proyecto**

IA-DataFlow es un ecosistema inteligente diseñado para centralizar, limpiar y estructurar datos (Excel, JSON, SQL) de forma automática. El sistema utiliza una arquitectura híbrida: **IA Local** para privacidad y procesamiento de bajo costo, y **IA Cloud (Gemini)** para tareas de alta complejidad y contexto masivo.

🧠 1. Conceptos Fundamentales de IA

🤖 ¿Qué es una IA?

Es un sistema basado en **Redes Neuronales** capaz de procesar lenguaje natural mediante la predicción de tokens. En nuestro contexto, no solo "chatea", sino que actúa como un **Agente**: una entidad capaz de ejecutar código Python para manipular archivos y tomar decisiones lógicas.

⚙️ Fases de Entrenamiento

1. **Pre-entrenamiento:** La IA aprende conceptos generales (realizado por Google/Meta).
2. **Fine-Tuning (Ajuste Fino):** Se reentrena el modelo con ejemplos específicos de "Datos Sucios → Datos Limpios".
3. **RAG (Retrieval Augmented Generation):** Se le da acceso a una base de datos externa para que "consulte" antes de responder.
4. **Agentic Workflow:** Se le otorgan "herramientas" (ej. librerías de Excel) para que las use según la necesidad.

🛠️ 2. Estrategia de Modelos para el Proyecto

Para que el sistema sea capaz de recibir cualquier formato y estructurarlo, utilizaremos:

Modelo	Tipo	Rol en IA-DataFlow
DeepSeek-R1 (Distill)	🏠 Local	Razonamiento lógico para detectar repetidos y datos faltantes.

Modelo	Tipo	Rol en IA-DataFlow
Qwen2.5-Coder	🏠 Local	Generación de scripts automáticos para ETL y transformación de JSON.
Gemini 2.5 Pro	☁️ Cloud	Análisis de archivos masivos y reportes ejecutivos finales.

💻 3. Evaluación de Infraestructura (Team IA)

> ⓘ **Estado de la Red**
>
> La prueba de conectividad mediante **ngrok** y **LM Studio** fue exitosa ✅. Esto permite que los nodos con menos hardware consuman la IA procesada en el nodo maestro.

🟢 Nivel: Servidor Maestro (High-End)

- **Juan Diego Mejía** * 💾 32 GB RAM | 🎮 RTX 5060 Ti 16GB
  - **Capacidad:** Puede entrenar (Fine-Tuning) modelos Llama-3 de 8B parámetros y correr modelos de hasta 14B-20B con fluidez.

🟡 Nivel: Soporte Operativo

- **Sebastián Bautista** (32 GB RAM | RTX 4050)
- **Andrés Andrade** (24 GB RAM | GTX 1650)
  - **Capacidad:** Ejecución de agentes locales y validación de outputs.

🔴 Nivel: Consumidores de API

- **Oscar, David, María, Pohlman** (8GB - 16GB RAM | Sin GPU)
  - **Rol:** Desarrollo de UI/UX, QA y consumo del backend procesado por Juan y Sebastián vía ngrok.

🔗 4. Fuentes Reales y Referencias

📺 Tutoriales y Guías Técnicas

- **Cómo crear agentes de datos (n8n + IA):** https://www.youtube.com/watch?v=AJfd-eVf5eU

- **Entrenamiento local UnSlot :**
  https://www.youtube.com/@HolaMundoDev/videos
  https://www.youtube.com/@nichonauta/videos
  https://www.youtube.com/@NullSafeArchitect/videos
  https://www.youtube.com/watch?v=xMm66CnUVgw
  https://www.youtube.com/watch?v=uzTPyCEX_C0
  https://www.youtube.com/@AlexOtano/videos
  https://www.youtube.com/watch?v=d9LGtygWEKQ
  https://www.youtube.com/watch?v=FFjvZV05vxM

Ingles
https://www.youtube.com/@NVIDIADeveloper/videos
https://www.youtube.com/@PromptEngineer48/videos
https://www.youtube.com/@DavidOndrej/videos
https://www.youtube.com/watch?v=7gXB0wnCvLY
https://www.youtube.com/@amplifyabhi/videos
https://www.youtube.com/watch?v=Wjrdr0NU4Sk&t=158s
https://www.youtube.com/@NetworkChuck/videos
https://www.youtube.com/watch?v=syH-T9OSMqk
https://www.youtube.com/@decodo_official/videos
https://www.youtube.com/watch?v=rp5EwOogWEw
https://www.youtube.com/@zenvanriel/videos
https://www.youtube.com/watch?v=pxhkDaKzBaY
https://www.youtube.com/@warpdotdev/videos
https://www.youtube.com/watch?v=QKdKcFjjZhE
https://www.youtube.com/watch?v=WzhPd4mVCJE
https://www.youtube.com/@NetworkCoder/videos
https://www.youtube.com/@TechWithTim/videos

- **Uso de LM Studio como Servidor API:** https://www.youtube.com/watch?v=Zp80m7V9oE0
  https://www.youtube.com/watch?v=oVlVUCdTLlg

📖 Documentación y Artículos

- **Google Cloud - Fine-Tuning de Gemini:** https://cloud.google.com/vertex-ai/generative-ai/docs/models/gemini-supervised-tuning
- **IBM - RAG vs Fine-tuning:** https://www.ibm.com/think/topics/rag-vs-fine-tuning
- **DeepSeek-V3 Technical Report:** https://github.com/deepseek-ai/DeepSeek-V3

📈 5. Hoja de Ruta (Next Steps)

1. **Configurar Agentes:** En lugar de solo entrenar, usaremos **Herramientas (Tools)** para que la IA llame a funciones de limpieza.
2. **Pipeline de Datos:** * `Input (Excel/JSON) -> Agente Local (Detección de errores) -> Agente Gemini (Estructuración) -> Output (Reporte)`.
3. **Escalado:** Juan Diego expone el endpoint de **LM Studio** por ngrok para que todo el equipo trabaje sobre el mismo cerebro local.

🏗️ Guía Técnica: Cómo Entrenar tu Propia IA (Fine-Tuning Local)

1. ¿Qué datos necesitas en cada fase de entrenamiento?

Fase	Datos Necesarios	Formato / Requisito
Recolección	Pares de `Input` (Datos Sucios) y `Output` (JSON estructurado).	Al menos 500 a 1,000 ejemplos para calidad mínima.
Formateo	Un archivo de texto donde se use un "Template".	Formato `.JSONL` (JSON Lines).
Validación	Un set de datos que la IA "no haya visto" durante el entrenamiento.	10% de tus datos totales.

Ejemplo de dato para IA-DataFlow:

JSON

```
{"instruction": "Limpia y estructura los datos.", "input": "id: 1, nombre: Juan, fecha: 2024-01-01; id:1, nombre: Juan...", "output": "[{\"id\": 1, \"nombre\": \"Juan\", \"fecha\": \"2024-01-01\"}]"}
```

---

2. Software Detallado para el Entrenamiento

Para hacerlo en tu máquina con **32GB de RAM y 16GB de VRAM**, este es el kit de herramientas:

1. **Unsloth (Recomendado):** Es la librería más rápida y que menos memoria consume para entrenar modelos como Llama-3 o Mistral. Reduce el uso de VRAM en un 70%.
   - *Link:* Unsloth GitHub

2. **Axolotl:** Una herramienta de línea de comandos que facilita el entrenamiento mediante archivos de configuración `.yaml`.
3. **Hugging Face TRL:** Para el entrenamiento de refuerzo.
4. **Google Colab (Opcional):** Si quieres dejar tu PC libre mientras entrenas, puedes usar sus GPUs gratis/pago.
5. **Weights & Biases (W&B):** Para ver las gráficas de cómo va aprendiendo tu IA y si se está "equivocando".

---

3. Fases Detalladas del Entrenamiento Local

1. **Tokenización:** Convertir tus Excels y JSONs en números que la IA entienda.
2. **Configuración de Hiperparámetros:** Decidir qué tan rápido aprende (`Learning Rate`) y cuánta memoria usará (`Batch Size`).
3. **Entrenamiento (The Run):** Aquí tu GPU trabajará al 100%. Con tu 5060 Ti, un entrenamiento de este tipo puede tardar de **2 a 6 horas**.
4. **Cuantización (GGUF):** Una vez entrenada, conviertes el modelo a formato `.GGUF` para poder usarlo en **LM Studio**.

📺 Videos Recomendados para Entrenar tu Propia IA

Aquí tienes fuentes reales y visuales para aprender el proceso paso a paso:

- **Fine-Tuning con Unsloth (El más fácil y rápido):**
  - Ver video: Mistral/Llama Fine-Tuning with Unsloth
- **Entrenar IA con tus propios documentos (Guía completa):**
  - Ver video: How to Fine-Tune LLMs on your own data
- **Conceptos de Fine-Tuning vs RAG (Cuándo hacer qué):**
  - Ver video: Fine-tuning vs RAG - Which one to use?

💡 Nota para el modelo de Gemini (Versión Paga)

Como mencionaste que quieres usar **Gemini Pro (Suscripción)**:

Google no te deja "reentrenar" el modelo base desde cero, pero ofrece **Google AI Studio Tuning**.

- **Software:** Google AI Studio.
- **Proceso:** Subes tu CSV directamente a la plataforma, seleccionas "Create Tuned Model", y Google usa sus servidores para crear una versión de Gemini que habla exactamente como tú quieres para IA-DataFlow.

Consejo de Arquitectura

Dado que eres analista, te sugiero que el **Fine-Tuning** lo uses solo para que la IA aprenda el **formato de salida**, y uses **RAG** para que la IA lea los **datos nuevos**. Entrenar una IA con datos que cambian todos los días (como contabilidad) es muy costoso; es mejor que aprenda a "leer" y "limpiar" una vez, y luego solo le pases los archivos.

#ia-dataflow #software-architecture #ai-agents #local-llm